

PARTNERS & SPONSORS



ORGANIZERS



WYDZIAŁ ELEKTRONIKI,
TELEKOMUNIKACJI
I INFORMATYKI

GOLD SPONSORS



PATRONS



PATRONAT HONOROWY
Prezydent
Miasta Gdańska



„Jaki mieliśmy przychód w Q3?”



PRÓBA 1

4,2 mln

PRÓBA 2

3,8 mln

PRÓBA 3

5,1 mln

„Jaki mieliśmy przychód w Q3?”



PRÓBA 1

4,2 mln

PRÓBA 2

3,8 mln

PRÓBA 3

5,1 mln

BRAWO – TAK WŁAŚNIE WYGLĄDA PRACA Z AGENTAMI LLM

„Jaki mieliśmy przychód w Q3?”



PRÓBA 1

4,2 mln

PRÓBA 2

3,8 mln

PRÓBA 3

5,1 mln

Agent odpowiada pewnie — nawet gdy nie zna prawdy.

100% pewności siebie ≠ 100% poprawności



WSTAŃ

**jeśli budujesz, wdrażasz lub po prostu używasz
agentów AI.**



USIĄDŹ

jeśli Twój agent choć raz udzielił innej odpowiedzi na tak samo zadane pytanie.



USIĄDŹ

jeśli agent był gotowy w 2–3 tygodnie, a governance nadal czeka na liście “do zrobienia”.



USIĄDŹ

**jeśli Twój agent choć raz zwrócił nieprawdziwe lub
wymyślone dane.**



USIĄDŹ

**jeśli na złą odpowiedź reagujesz dłuższym promptem
zamiast lepszymi danymi.**



USIĄDŹ

jeśli Ty/Twój zespół/firma kupiła nowy framework AI, ale definicje metryk nadal są niespójne.



USIĄDŹ

jeśli agent trafił do zarządu, zanim dane zostały uporządkowane.



Agenci LLM bez iluzji

To dane, semantyka i ewaluacja — nie sam model — decydują o jakości agenta.

Bartłomiej Graczyk

Head of Digital Technologies Transformation & Chief Architect | Polpharma Group

Paweł Potasiński

CTO | Infinite Services

Wybierz najprostszy kontrolowalny wzorzec



Najlepszy agent to często ten, którego nie musiałeś zbudować.

Wybierz najprostszy kontrolowalny wzorzec



4

Własny agent

Dopiero gdy 1–3 nie wystarczą. Najdroższy w budowie i utrzymaniu.

3

Agent z pudełka (OOTB)

Ktoś już go zbudował, zabezpieczył i utrzymuje.

2

Skill — wąska umiejętność

Jedno zadanie, opisane, wielokrotnego użytku.

1

Prompt + kontekst

Rozwiązuje większość potrzeb.

OSTATECZNOŚĆ

START

Najlepszy agent to często ten, którego nie musiałeś zbudować.

Prompt steruje zachowaniem — nie naprawia fundamentu danych



CO PROMPT POTRAFI

- ✓ Ustawić rolę i ton
- ✓ Określić format odpowiedzi
- ✓ Wskazać sposób postępowania
- ✓ Ograniczyć styl i długość

CZEGO PROMPT NIE NAPRAWI

- ✗ Sprzecznych definicji metryk
- ✗ Złego źródła prawdy
- ✗ Braków w jakości i aktualności danych
- ✗ Błędnych uprawnień

Prompt ustawia zachowanie modelu. Nie naprawi fundamentu danych.

Agent, agentowi nie jest równy



Wiedza i dokumenty

Agent konwersacyjny — Q&A w języku naturalnym.

np. Copilot w M365



Liczby i metryki

Data agent nad modelem semantycznym — wynik z zapytania.

np. Microsoft Fabric Data Agent



Działanie w procesie

Agent zadaniowy — ticket, zamówienie, workflow.

np. Copilot Studio



Kod

Agent programistyczny — pisze, refaktoryzuje, recenzuje.

np. GitHub Copilot

NIE MA JEDNEGO AGENTA DO WSZYSTKIEGO

Najpierw rodzaj odpowiedzialności — potem technologia agenta.

Losowość zaczyna się, gdy model sam wybiera znaczenie i źródło



Bez ograniczeń model sam wybiera znaczenie, źródło i kontekst.



Model generuje odpowiedź probabilistycznie.
Wiedza biznesowa musi być kontrolowana deterministycznie.

***Problem nie zaczyna się w modelu.
Zaczyna się w systemie, który zbudowaliśmy wokół niego.***



Najpierw fundament

Model jest ostatnią warstwą systemu — nie jego punktem wyjścia.

Pięć warstw zamienia model w kontrolowany system



**Agent jest tak dobry, jak warstwa, na której pracuje. Buduj od dołu.
Największa dźwignia jakości leży w źródłach, kontraktach i semantyce.**

Dobry agent opiera się na definicjach, źródłach i granicach



01 SEMANTYKA

Jedna definicja, nie siedem

Jeśli człowiek nie wskaże właściwej definicji przychodu, agent jej nie zgadnie.

02 ŹRÓDŁA

Source of truth, nie source of everything

Jedno autorytatywne źródło per klasa pytań — z właścicielem, priorytetem i datą obowiązywania.

03 GRANICE

Prawo do „nie wiem”

Brak wpisu w źródle oznacza odmowę lub eskalację — nigdy improwizację z kilku źródeł.

Agent nie zgaduje lepiej to system pozostawia mu mniej miejsca na zgadywanie.



DEMO

Ten sam model na dwóch różnych fundamentach



01 **POPRAWNOŚĆ**
Czy wynik jest właściwy?

02 **POWTARZALNOŚĆ**
Czy wynik jest stabilny?

03 **WYJAŚNIALNOŚĆ**
Czy wskazuje źródło?

Obserwuj mechanizm — nie tylko odpowiedź.

COUNT(*) zawyża liczbę zamówień niemal dwukrotnie



SŁABY AGENT

2,583

Wrong — counts line items / rows
COUNT(*)

DOBRY AGENT

1,313

Correct — counts distinct orders
COUNT(DISTINCT ORDER_ID)

CO ZROBIŁ FUNDAMENT?

Słaby agent nie miał metryki order_count ani opisu ziarnistości fact_sales. Dobry użył jawnej definicji i właściwej agregacji.

Różnicę zrobiła definicja metryki — nie dłuższy prompt.

Znajomość jednostki



SŁABY AGENT

0.1325

Wrong — raw decimal
AVG(DISCOUNT)

DOBRY AGENT

13.3%

Correct — converted to percentage
 $\text{AVG(DISCOUNT)} \times 100$

CO ZROBIŁ FUNDAMENT?

Słaby agent nie znał jednostki kolumny DISCOUNT. Dobry miał opis semantyki i metrykę, która automatycznie przelicza skalę.

Semantyka kolumny decyduje, czy agent wiec jakie znaczenie ma liczba

Sama suma zysku nie wyjaśnia, gdzie i dlaczego tracimy



SŁABY AGENT

Raw SUM(PROFIT)

Only dollar amounts
No margin %. No explanation.

DOBRY AGENT

Margin + context

Tables -8.6% · Bookcases -4.1%
Supplies -2.5% · heavy discounting

CO ZROBIŁ FUNDAMENT?

Słaby agent zwrócił surowy wynik. Dobry połączył sprzedaż, zysk i marżę oraz zastosował instrukcję wymagającą biznesowego wyjaśnienia.

Dobra odpowiedź łączy metrykę, kontekst i interpretację.

Jawna definicja „top” stabilizuje odpowiedź agenta



SŁABY AGENT

Different every time

Sales vs profit vs quantity
Product vs sub-category
Top 5 vs 10 vs all

DOBRY AGENT

Always the same

Top 5 sub-categories by sales
with profit and profit margin %

CO ZROBIŁ FUNDAMENT?

Pytanie było niejednoznaczne na trzech osiach. Verified Query przypięło metrykę, poziom agregacji i limit wyników.

Powtarzalność zaczyna się od jawnego znaczenia pytania.



Najpierw fundament – odsłona 2

Agent jest tak dobry jak jego źródła

RAG to mierzalny pipeline danych — każdy etap może zawieść



Każdy etap to osobne miejsce na błąd — i osobny punkt pomiaru.

INDEKSOWANIE (OFFLINE)

1 Ingest i parsowanie

OCR, tabele, nagłówki →
Markdown/JSON z zachowaną
strukturą dokumentu

2 Chunking

Po strukturze (sekcje), np. 300–800
tokenów;

3 Wzbogacanie

Metadane, streszczenie, encje i
terminy z glosariusza doklejone do
chunka

4 Embedding + indeks

Wektor; wersja modelu embeddingów
zapisana w indeksie

ZAPYTANIE (ONLINE)

5 Query rewrite

Dekompozycja pytania, synonimy z
glosariusza, filtry z metadanych

6 Hybrid retrieval

Wektor + filtr ACL (security trimming)
przed rankingiem

7 Reranking

Cross-encoder / semantic ranker; np.
top-k

8 Generacja z cytatem

Odpowiedź tylko z kontekstu; brak
kontekstu → „nie wiem”

Zły chunking i brak metadanych psują odpowiedź, zanim model ją zobaczy.

Metadane decydują, co agent znajdzie i czy może temu zaufać



MINIMALNY KONTRAKT METADANYCH DOKUMENTU

owner / source_id	Kto odpowiada za treść i jej korektę
status + version	approved > draft; w indeksie tylko wersja obowiązująca
valid_from / valid_to	Odcięcie treści nieaktualnych już na etapie filtra
domain / doc_type	Routing do właściwego indeksu i agenta
acl / classification	Security trimming, RODO, poziom poufności
language / glossary_terms	Mapowanie pojęć biznesowych na treść

SEMANTYKA DOKUMENTU

Chunk zna swój kontekst Tytuł dokumentu i ścieżka nagłówków doklejone do każdego fragmentu.
Tabele i liczby osobno Dane liczbowe jako struktura / SQL — nie tekst do embeddingu.
Jedno pojęcie, jedna definicja Glosariusz i synonimy z katalogu danych zasilają query rewrite.

Dokument bez właściciela, daty i statusu nie powinien trafić do indeksu.

Zaczynaj od RAG; agentowość dodawaj do działań wieloetapowych



Kryterium	RAG (retrieval → odpowiedź)	Agentic RAG / agent z narzędziami
Przepływ	Ograniczony przepływ: pytanie → retrieval → odpowiedź	Pętla: plan → narzędzie → obserwacja → kolejny krok
Kiedy	Q&A nad dokumentami: polityki, procedury, FAQ	Pytania wieloetapowe, łączenie źródeł, akcje w systemach
Dane	Indeks treści + metadane	Indeks + API / SQL / MCP z kontraktami i uprawnieniami
Koszt i latencja	Zwykle niższe i bardziej przewidywalne	Wyższe, zmienne (N wywołań, N narzędzi)
Ryzyko	Halucynacja przy słabym retrievalu	Jak w RAG + błędne akcje, pętle, nadmiar uprawnień
Testowanie	Zbiór pytań → ocena odpowiedzi	Ocena trajektorii: wybór narzędzi, kroki, wynik

Zaczynaj od RAG. Agentowość dodawaj tam, gdzie pojedynczy retrieval nie wystarcza.

Bez golden setu nie wiesz, czy agent naprawdę jest lepszy



1 Golden set

Reprezentatywny zestaw pytań biznesowych z odpowiedzią i źródłem

2 Ocena offline

LLM-as-judge + próbka ręczna; każda zmiana = test regresji

3 Bramka wdrożeniowa

Progi jakości w CI/CD; brak progu = brak wdrożenia

4 Monitoring online

Oceny użytkowników, tracing, nowe pytania wracają do golden setu

CO MIERZYĆ

RETRIEVAL

Context recall / precision

Czy właściwe fragmenty trafiły do kontekstu

RETRIEVAL

Hit rate

Na której pozycji jest dobre źródło

GENERACJA

Groundedness (faithfulness)

Czy odpowiedź wynika z kontekstu, a nie z pamięci modelu

GENERACJA

Correctness / relevance

Czy zgadza się z wzorcem i odpowiada na pytanie

AGENT

Tool-call accuracy / task success

Czy wybrał właściwe narzędzie i zakończył zadanie

OPERACJE

% „nie wiem”

Czy rozwiązanie jest używalne i opłacalne

Decyzje, które oddzielają eksperyment od wdrożenia produkcyjnego



OBSZAR	ANTYWZORZEC	WZORZEC
Definicje	✗ Agent zgaduje, co to marża, koszt, zysk...	✓ Jedna definicja w warstwie semantycznej
Źródła	✗ „Podłączmy wszystkie dane”	✓ Zaufane źródło danych per domena
Jakość	✗ „Naprawimy później”	✓ Kontrakty na dane i reguły jakości przed agentem
Zakres	✗ Jeden prompt na 400 linii	✓ Dobrze opisana, wąska rola
Nadzór	Reakcja dopiero po incydencie	Monitoring, właściciel i test regresji

Gotowość produkcyjna wymaga wartości, danych, kontroli i operacji



01 PROBLEM I WARTOŚĆ

- ❑ Wspiera konkretną decyzję lub zadanie
- ❑ Znamy koszt niezrobienia (ROI)
- ❑ Ma właściciela biznesowego

03 ZACHOWANIE AGENTA

- ❑ Cytuje źródło odpowiedzi
- ❑ Potrafi powiedzieć „nie wiem”
- ❑ Rozróżnia brak danych od braku uprawnień
- ❑ Ma ograniczony zakres

02 DANE

- ❑ Jest uzgodniona definicja
- ❑ Wskazano źródło prawdy
- ❑ Właściciel i kryteria jakości
- ❑ Wiemy, jak stara jest odpowiedź

04 OPERACJE

- ❑ Zestaw testów referencyjnych
- ❑ Odpowiedzi są monitorowane
- ❑ Istnieje ścieżka eskalacji
- ❑ Znane warunki zatrzymania

Kontrolowany fundament daje tę samą odpowieź za każdym razem



To samo pytanie: „Jaki mieliśmy przychód w Q3?”

4,2 mln

4,2 mln

4,2 mln

To nie szczęście. To mechanizm.

SQLDay Lite 2026 Gdańsk

Session feedback



Najpierw fundament. Agent na końcu.



Bartłomiej Graczyk

[linkedin.com/in/bartlomiejgraczyk](https://www.linkedin.com/in/bartlomiejgraczyk)



Paweł Potasiński

<https://www.linkedin.com/in/pawelpotasinski/>

Dane definiują granice tego, co agent może wiedzieć.
Ewaluacja definiuje granice tego, czemu możemy zaufać.



Data
Community