

PARTNERS & SPONSORS



ORGANIZERS



WYDZIAŁ ELEKTRONIKI,
TELEKOMUNIKACJI
I INFORMATYKI

GOLD SPONSORS



PATRONS



PATRONAT HONOROWY

Prezydent
Miasta Gdańska





Ontologia Palantir Foundry jako brakujące ogniwo między SQL a LLM

Grzegorz Brodny
Remigiusz Tunowski

O nas – Grzegorz Brodny



- 13+ lat doświadczenia z danymi (głównie BI)
- 4+ lata w AWS.
- Lider Trójmiejskiego oddziału Data Community.
- Cloud Senior Data Engineer w Future Processing.
- Doktor informatyki z dziedziny Affective Computing.
- Palantir sceptyk

Kontakt:

- grzegorz.brodny@datacommunity.pl
- <https://www.linkedin.com/in/grzegorz-brodny-13417393/>



O nas – Remigiusz Tunowski




- 15 lat doświadczenia w świecie danych (BI)
- Business Intelligence Consultant w Future Processing
- Entuzjasta Palantira i dostarczania wartości dla biznesu
- Doktor z obszaru Business Intelligence
- Autor książki i publikacji dot. BI

Kontakt:

- rtunowski@future-processing.com
- <https://www.linkedin.com/in/remigiusz-tunowski-97897466/>

Agenda



Dwa dema na żywo w Palantir Foundry – na dwóch różnych projektach i dwóch różnych dziedzinach.

Pytania zbieramy na koniec. Będzie na nie czas.

To nie jest dashboard.

Acknowledge Review Refer for Follow-up						
Patient No 1 ↓ 9	Risk Band	Risk Prediction	Review Status	Referral Status	Sex	Age
1	low	1%	Reviewed	Not Referred	Female	35
2	low	4%	No value	No value	Female	70
3	low	3%	No value	No value	Female	75

Aplikacja operacyjna na danych – bez własnego backendu, bez własnego API, bez frontendu do utrzymania.



Koncepcja i kontekst ontologii

Cały Palantir – gdzie jesteśmy?

Gotham

obronność, wywiad, służby
śledztwa i analiza na grafie encji; od 2008

poza zakresem

Foundry

przemysł, biznes, administracja
platforma danych end-to-end; tu żyje Ontologia

TEMAT PRELEKCJI

AIP

warstwa AI nad Gotham i Foundry
agenci, LLM, AIP Logic, AIP Assist; od 2023

wchodzimy: AIP Logic

Apollo

dostarczanie i utrzymanie
ciągłe wdrożenia: chmura, on-prem, edge

poza zakresem

ONTOLOGIA

obiekty · linki · akcje · funkcje
wspólny język ludzi, aplikacji i modeli

Ontologia jest tym ogniwem: nad SQL-em, pod LLM-em. Cała reszta prelekcji rozbiera ją na części.


Co daje Ontologia w Palantir?

- **Jedna definicja** – definiujesz raz, konsumują je Object Explorer, Workshop, Quiver i OSDK.
- **Linki zamiast JOIN-ów** – relacja opisana raz, potem chodzenie po grafie
- **Write-back** – decyzja wraca jako Akcja: walidowana i audytowalna
- **Governance przy obiektach** – uprawnienia i markingi na property
- **Język biznesu** – Zamówienie i Klient zamiast DIM_CUST_V2
- **Workshop** – aplikacja operacyjna na obiektach, bez własnego backendu

Hurtownia odpowiada na pytania. Ontologia pozwala też działać – i pamięta to działanie.



Gdzie w Palantir Foundry siedzi Ontologia?




Obiekty są indeksowane w osobnym storage, a nie odpytywane w locie z Datasets. Zapis z aplikacji idzie przez Akcje – system źródłowy zostaje nietknięty.



Jak zbudowana jest Ontologia?

Czym jest ontologia?

- „Digital Twin” obiektów biznesowych i logiki
- Poziom semantyki biznesowej
- Biznesowy opis danych i relacji
 - Opis kolumn
 - Referencje do innych obiektów (linki)
 - Graf relacji między obiektami
- Możliwość uzupełnienia przez biznes
- Modelowanie jak diagram ERD



Czym jest ontologia? (technicznie)

- Paradygmat obiektowy nie relacyjny (object centric)
- 1+ data sets per obiekt
- Własna definicja danych
- Kopia danych, zaindeksowana we własnym storage'u
 - Podobny do Delta Lake format
- Struktura:
 - Preferowana 3NF do odczytu Ontologii (snowflake schema)
 - Rzadkie modyfikacje wierszy (głównie nowe)


Ontology		Relational Database*
Object Type		Table
Property		Column
Object	→ is like →	Row
Link Type		Join
Object Set		Query
Action Type		Stored Procedure
Function		User-defined Function

Where the ontology take place in BI


Variant 1



Variant 2



Variant 3



Z czego składa się Ontologia?

Object Type **Zamówienie**

description: *Zamówienie złożone przez klienta w systemie sprzedaży*

PROPERTIES – KOLUMNY Z TYPEM I OPISEM

id	string	<i>primary key</i>
Numer zamówienia	string	<i>title property – nazwa wyświetlana</i>
Wartość netto	double	<i>kwota bez VAT</i>
Data dostawy	timestamp	<i>termin obiecany klientowi</i>
Status	enum	<i>nowe / w realizacji / zamknięte</i>

LINK TYPES – RELACJE W MODELU

→ **Klient** many-to-one

→ **Pozycja zamówienia** one-to-many

→ **Handlowiec** many-to-one

ACTIONS – ZAPIS DO ONTOLOGII

Zatwierdź zamówienie

Zmień termin dostawy

Anuluj

FUNCTIONS – LOGIKA NA OBIEKCIE

marża()

czyOpóźnione()

Każdy element ma opis w języku biznesu – ten sam opis czyta analityk w katalogu i model w prompcie.

SQL kontra linki

HURTOWNIA – JOIN PRZY KAŻDYM ZAPYTANIU

```
SELECT p.*, pr.risk_band, mr.test_auc  
FROM patient p  
JOIN prediction pr ON pr.patient_uid = p.patient_uid  
JOIN model_run mr ON mr.model_run_id = pr.model_run_id
```

Relację odtwarzasz w każdym zapytaniu. Schemat znasz tylko ty.

ONTOLOGIA – RELACJA OPISANA RAZ

```
patient  
  → predictions      (HAS_PREDICTION, 1:n)  
    → scoredBy      (SCORED_BY, n:1)  
searchAround() · pivot · pivotTo()
```

Dwukierunkowa. Ta sama dla dashboardu, aplikacji i modelu językowego.

Obiekt i link definiujesz raz, przy modelu. Potem nikt już nie pisze JOIN-a: ani analityk, ani aplikacja, ani model.

Ten sam łańcuch obiektów zobaczycie za kilka minut kliknięty na żywo – bez ani jednego JOIN-a.



DEMO



Ontologia a LLM

Czyli ontologia w praktyce

Klasyczny RAG kontra ontologia

KLASYCZNY RAG

dokumenty pocięte na chunki, embeddingi
retrieval po podobieństwie wektorowym
model składa odpowiedź z fragmentów

zapis? model musi sam napisać SQL

„co jest podobne do pytania”

ONTOLOGIA JAKO NARZĘDZIE

typowane obiekty, nie fragmenty tekstu
jawnie wybrane property i link types
opisy z modelu jako metadane w prompcie
zapis wyłącznie przez Akcje – kontrakt

„co jest prawdą i co wolno z tym zrobić”

To nie są konkurenci. Ontologia jest tym, czego klasycznemu RAG-owi brakuje: strukturą i prawem zapisu.

Co w Ontologii pomaga LLM?

Kontekst biznesowy w prompcie

opis właściwości trafia bezpośrednio do modelu razem z danymi –
nie leży w Confluence

Grounding na strukturze

structured data to mniej halucynacji,
bez tego LLM polega czysto na podobieństwie wektorowym

Zapis przez Akcje

kontrakt zamiast SQL-a pisanego przez model: walidacja,
uprawnienia, ślad w audycie

Uprawnienia filtrują kontekst

model nie zobaczy tego, do czego użytkownik nie ma dostępu

Domyślnie nie dotyka systemu źródłowego – zapis idzie do ontologii przez Akcje.

Przekazanie struktury ontologii wraz z opisami do LLM



Native tool calling • 1 tool

et of objects instead of the entire table. Object set identifiers appear as ri.object-set.<some string>.<some string>.<some string> and point to a subset of the objects in a table. To use an object set identifier, include the table name as an argument with the object set identifier as its value. Note that starting from an object set is optional. Only include tables where you have an object set identifier and the user's questions suggest querying a subset rather than all objects.

Queryable tables are as follows (formatted <tableName>: <description>):

GrzegorzBWorkOrder:

GrzegorzBEquipment:

OntzCompassBakeryEmployee:

OntzCompassBakeryComponent: A component or part installed on a piece of equipment in the Compass Bakery, tracking part numbers, categories, and installation dates.

OntzCompassBakeryComponent grzegorzBworkOrders GrzegorzBWorkOrder ontzCompassBakery

Components: Junction table for many-to-many relationship between OntzCompassBakeryComponent and GrzegorzBWorkOrder

Each table's columns are as follows (formatted <columnName> (<dataType>): <description>):

GrzegorzBWorkOrder

PRIMARY KEY workOrderId (TEXT): Work Order Id

title (TEXT): Title

affectedBatchId (TEXT): Affected Batch Id

assignedTo (TEXT): Assigned To

closedTs (TIMESTAMP): Closed Ts

daysOpen (BIGINT): Days Open

description (TEXT): Description

equipmentId (TEXT): Equipment Id

fixType (TEXT): Fix Type

issueCategory (TEXT): Issue Category

priority (TEXT): Priority

qaSignoffBy (TEXT): Qa Signoff By

reportedBy (TEXT): Reported By


reportedTs (TIMESTAMP): Reported Ts

resolution (TEXT): Resolution

sanitationSignoffBy (TEXT): Sanitation Signoff By

status (TEXT): Status

AIP Logic – jak to działa?





Query objects filtruje dane przez object i property security policies – model nie zobaczy tego, do czego użytkownik nie ma uprawnień.



DEMO

AIP Logic (1)

- Wyjście od obiektu, do obiektu powiązanego
- Filtrowanie
- Uruchomienie LLMa
 - Ustawienie LLMa
 - Ustrukturyzowany output

Inputs

- house

Neighborhood: Neighborhood

Starting object set

- Convert house to ObjectSet

Search around: Neighborhood

Neighborhood → neighborhood

Filter

Search around

Sort

Cast

neighbors: Houses

Starting object set

- All Houses

Filter: Houses

All are true

- 123 Zipcode = Equals house.Zipcode
- All are true
- 99 Id = Equals house.Id
- 123 Sqft Living ≥ Greater than or equal to house.Lower Sqft
- 123 Sqft Living ≤ Less than or equal to house.Upper Sqft

Filter

Search around

Sort

Cast

AIP Logic (2)

- Wyjście od obiektu, do obiektu powiązanego
- Filtrowanie
- Konfiguracja LLMa
- Ustrukturyzowany output
 - Ograniczenie halucynacji
- Evals – testowanie LLMa
 - Wejście + oczekiwane wyjście

Output

{ } Struct(Explanation: String, Score: Double, List of compared houses: String, Clasification: String, Hous

Filter...

Name	Type		
Explanation	String		
Score	Double		
List of compared houses	String		
Clasification	String		
House name	String		

+ Add field

123 Integer

123 Long

123 Short

String

Struct

Timestamp

Value type



AIP Logic (3) – structured output

Debugger

Use the detailed execution log below to troubleshoot any issues in your Logic.

Execution started

Neighborhood

neighbors

neighbors - formatted

Neighborhood - formatted

Use LLM

Successfully ran

```
{
  "Explanation": "Subject (4 bd / 2.5 ba - 350,000$ - 98038",
  "Score": 8.2,
  "List of compared houses": "1) Comp",
  "Classification": "UNDERPRICED",
  "House name": "4 bd / 2.5 ba - 350,000$ - 98038"
}
```

Token usage by model In 13.16s

Preview run

Do a preview run of this logic to ensure its output looks as expected.

Ontology edits are not applied when running a preview in Logic. Publish your Logic function to apply edits where functions are used.

Function inputs

house

4 bd / 2.5 ba - 350,000\$ - 98038

Function output

(x) Use LLM

Successfully ran

```
{
  "Explanation": "Subject (4 bd / 2.5 ba - 350,000$ - 98038",
  "Score": 8.2,
  "List of compared houses": "1) Comp",
  "Classification": "UNDERPRICED",
  "House name": "4 bd / 2.5 ba - 350,000$ - 98038"
}
```

Token usage by model In 13.16s

Config

Preview

Bulk test

Evals

Runs

Versions

Usage



Czy warto stosować ontologię?

Czy warto stosować ontologię?



**“MOIM ZDANIEM TO NIE MA TAK,
ŻE DOBRZE, ALBO NIEDOBRZE...”**



Ograniczenia ontologii

- Preferowane 3NF – enterprise DWH lub model płatka śniegu (zamiast gwiazdy)
 - Nastawienie na rzadkie aktualizacje, długo żyjące dane
 - Unikalność wierszy, deduplikacja, brak złożonych kluczy obcych
 - Obiektość podejścia
- Wymaga dodatkowego narzutu – zdefiniowania opisów kolumn, linków (relacji), uprawnień – w zamian daje governance
- Wprowadza dodatkową warstwę nad silnik analityczny (Spark/SQL)
- Pracuje lepiej na zagregowanych danych (mniejszy wolumen)
 - Agregacje w trybie ACCURATE (może być wolne) lub APPROXIMATE
- Droższe rozwiązanie, klasy enterprise
- Duży vendor-lock

Czy to ma sens?

- W Foundry Ontologia stanowi serce całego rozwiązania – centralny punkt
- Microsoft Fabric – moduł Digital Twin Builder (Real-time intelligence, preview)
 - Bez write-backów
 - Dodaje traversal po zależnościach, AI Agent Grounding
- Databricks – Genie Ontology
 - Pamięć dla agentów, model samuczący się
- SAP HANA Cloud - Knowledge Graph Engine, oparta na zdefiniowanych obiektach (w dużej mierze gotowe) – bliskie standardowi OWL

	Palantir Foundry	Microsoft Fabric	Databricks	SAP
Feature name	Ontology (Semantic, Kinetic, Dynamic layers)	Digital Twin Builder - Ontology	Genie Ontology / Unity Catalog	HANA Cloud Knowledge Graph Engine
Start	Introduced as first-class product concept, 2021	Announced at Microsoft Build, May 2025	Announced at Data + AI Summit (DAIS), June 2026	Announced at SAP TechEd, September 2024
Current status	GA	Preview	Public Preview	GA (end of Q1 2025)
Role of ontology	Central, mandatory operational layer	Optional module within Real-Time Intelligence workload	Context/grounding layer for AI agents	Semantic layer on top of BDC/HANA data
Write-back / actions	Yes, both	Limited - mainly read/visualization (dashboards, Power BI)	No - a context layer, not an operational/action layer	No - a semantic/query layer, not an action layer
Other	Proprietary model	Proprietary metamodel	Built on Unity Catalog metadata	Native support for OWL, SHACL, and federated SPARQL
Starting point for modeling	Modeled from scratch by the user	Modeled from scratch	Auto-generated/learned from data, dashboards, queries	Partially pre-built - business entities already defined



Podsumowanie



Kiedy stosować?

Bierz, jeśli...	Odpuść, jeśli...
biznes ma podejmować decyzje w narzędziu, nie w Excelu	potrzebujesz raportów i dashboardów
dane z wielu systemów, nikt nie zna jednej definicji	jedno źródło, model już ustabilizowany
audyt i traceability są wymogiem, nie życzeniem	duży wolumen i częste update'y wierszy
LLM ma sięgać po dane firmowe z uprawnieniami	LLM to eksperyment/PoC z ograniczonym budżetem

Model Success Fee – chcesz mieć mierzalną wartość



Podsumowanie

- Ontologia wspiera działanie operacyjne – zapis wyłącznie przez akcję (parametry, uprawnienia, audyt)
 - Wspiera pracę z LLMem – strukturyzuje kontekst danych (kontrakt vs podobieństwo wektorowe)
 - Wymaga dodatkowego wkładu, strukturyzowania oraz kosztów (+ Vendor Lock)
-
- *Ontologia jest ogniwem: nad SQL-em (lub Pythonem), pod LLM-em. Ale tylko wtedy, gdy ktoś realnie działa na danych, a nie tylko je ogląda.*



Jak to sprawdzić samemu?

- Free Dev Tier
 - <https://www.palantir.com/developers/>
- Dane z kaggle:
 - <https://www.kaggle.com/datasets/sukhmandeepsinghbrar/housing-price-dataset>
 - <https://www.kaggle.com/code/alphiree/cvds-risk-prediction-notebook-full/notebook>

SQLDay Lite 2026 Gdańsk

Session feedback



Pytania?

